Universidade do Estado de Minas Gerais
Graduação em Engenharia da Computação
Sistemas Inteligentes II
Trabalho 1

Sofia Anita Miranda

15 de novembro de 2022

1 Descrição dos Dados

A base de dados escolhida para a realização desse trabalho, chamada de Auto MPG Data Set, pode ser encontrada no repositório UCI. As informações contidas nessa base de dados estão relacionadas ao consumo de combustivel de automóveis no trânsito de cidade, descrito pelo atributo milhas por galão(mpg), e pode ser associado a 3 atributos discretos multivalorados e 5 contínuos.[1]

Vale considerar que a versão utilizada possui algumas modificações quando comparada com a base de dados original, que foi disponibilizada pela Carnegie Mellon University, e apresentada em 1983, na American Statistical Association Exposition. Na versão utilizada, uma limpeza de dados já foi previamente realizada, exluindo 8 colunas que possuiam valores faltantes.

Analisando as informações da base de dados, observa-se que ela é formada pelos seguintes atributos:

1. mpg: continuous
2. cylinders: multi-valued discrete
3. displacement: continuous
4. horsepower: continuous
5. weight: continuous
6. acceleration: continuous
7. model year: multi-valued discrete
8. origin: multi-valued discrete
9. car name: string (unique for each instance)

Se tratando da quantidade de amostras, de acordo com as informações disponibilizadas no site UCI, a base possui um total de 398 amostras, que foram confirmadas quando a base foi carregada no algoritmo contruído para analisar esses dados.

2 Análise dos Dados

Com o intuido de entender melhor a relação entre os dados, foi feito uma analise em cima de cada atributo da base de dados. Nessa etapa, foi levantado questões como a média, o desvio padrão, a variância, a matriz de correlação, o valor mínimo e máximo de cada atributo, que podem ser observados na tabela 1.

	MPG	Cylinders	Horsepower	Weight	Acceleration	Model year
Média	23,51	5,45	0	2970,42	15,56	76,01
Desvio padrão	7,81	1,70	104,26	846,84	2,75	3,69
Variâcia	61,08	2,89	?	717140,99	7,60	13,67
Valor Minimo	9,0	3	100	1613	8,0	70
Valor Máximo	46,6	8	?	5140	24,8	82

Tabela 1: Análise dos dados

Durante essa análise, foi possível perceber que a coluna referente a potêcia de cada automóvel (Horsepower) possuia alguma amostra com valor faltante. Logo, o proximo passo foi removê-los do dataset.

2.1 Pré-processamento

Até essa etapa, a base de dados foi tratada levando em cosideração todos atributos que pertencem a ela. Contudo, o objetivo da análise desses dados para esse trabalho é buscar a relação que existe entre o consumo de combustivel com o peso do veículo. Portanto, as demais colunas serão ignoradas.

Assim, o primeiro passo foi analisar a dispersão dos dados, relacionando os atributos que são de interesse. Como se trata de uma base de dados norte-americana, percebe-se que alguns dos atributos não estão de acordo com o sistema internacional de unidades, como por exemplo o atributo mpg(miles per gallon). Assim, para facilitar o entendimento, esses valores foram transformados para km/l(quilometros por litro), bem como a coluna weight, que foi transformada de libras para quilogramas. Essa dispersão pode ser analisada pelo gráfico da Figura 1.

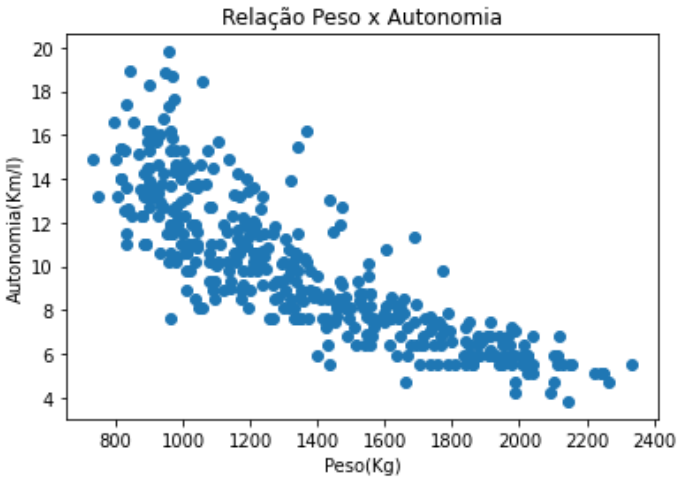


Figura 1: Dispersão dos dados

Depois de analisar esse gráfico, o passo seguinte foi procurar a existência de dados duplicados e assim como dados faltantes na base. Não foi encontrado dados duplicados, mas quando consideramos dados faltantes foi diferente. Aqui, foi encontrado algumas instâncias que encaixavam nessa analise, mas somente no atributo Horsepower, que representa a potência do veículo. Como essa é uma coluna que não será utilizada, esses valores foram apagados, já que a sua falta não faria diferença no resultado da analise que buscamos.

Outro passo importante na preparação dos dados é a normalização. Nessa etapa, o obejtivo é transformar valores númericos para uma escala comum, sem distorcer as diferenças de intervalos de valores nem perder informações.

Após esses passos, a base já estava pronta para a etapa de processamento dos dados.

3 Metodologia

Visto que essa base não possui uma coluna de classificação, partimos para o agrupamento dos dados, que tem como objetivo unir aqueles que são semelhantes. O método utilizado foi o KMeans, e foram passados como parâmetros as 2 colunas principais: weight e mpg, separadas em x e y.

Após o processamento desse método, pode-se observar as classes formadas pelos gráficos da figura 2.

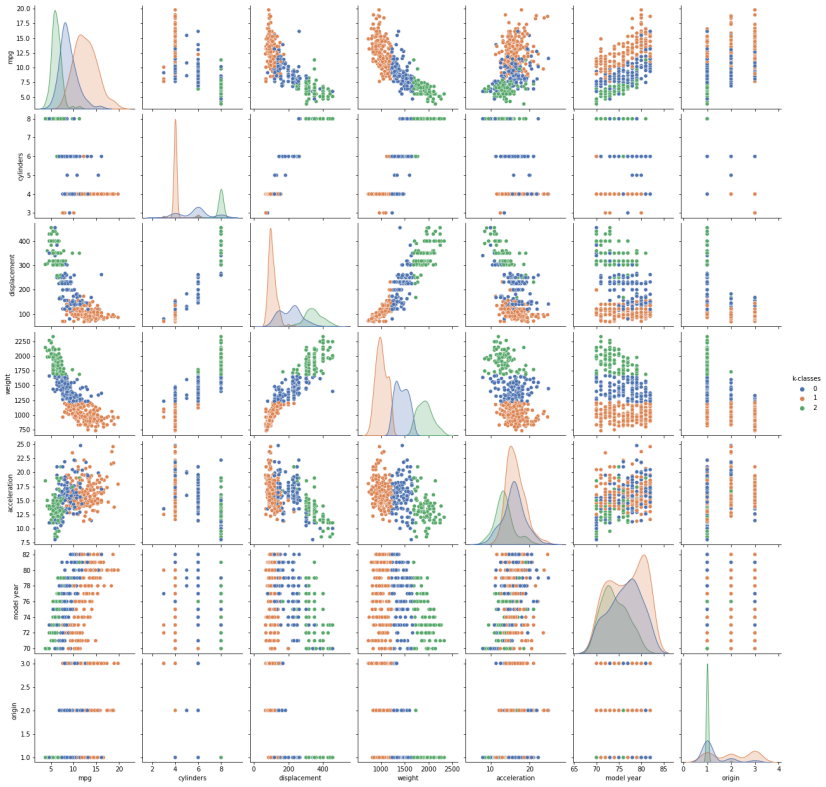


Figura 2: Classes formadas pelo método KMeans

A partir desse agrupamento de dados, o passo seguinte foi realizar a validação das classes criadas. Para isso, foi utilizado o método do tipo critério de validação relativo, que é utilizado para indicar

qual a melhor dentre duas ou mais partições.

Dentre os diversos métodos desse tipo, utilizado foi Davies-Bouldin. Nesse, quanto maior o valor do indice, melhor, já que isso representa baixas medidas de dispersão intragrupo, assim como grandes distâncias intragrupos. [2]

4 Experimentos Computacionais

Como dito anteriormente, o intuito em utilizar essa base de dados seria fazer uma relação entre o gasto de combustível em relação ao peso dos veículos. Sendo assim, os parâmetros passados para o método de agrupamento foram aqueles que representam essas informações, descritas na base como mpg e weight.

Para a validação desse agrupamento, o método aplicado foi o critério de validação relativo, especificamente Davies-Bouldin. Foram variados a quantidade de clusters de 2 a 11, afim de obter 10 amostras. Para cada um, foi retornado valores de Davies-Bouldin apresentados na tabela 2.

Número de clusters	Davies-Bouldin
2	0.5029252679735234
3	0.494614806368114
4	0.48390458413733767
5	0.5178415322323136
6	0.5338466760228465
7	0.5464267938582231
8	0.5061629919312158
9	0.4973112667237387
10	0.5061110016512418

Tabela 2: Validação de agrupamento

Aqui, percebe-se que a quantidade ideal de classes para essa base de dados é 4 classes.

5 Conclusão

Com a metodologia aplicada foi possível identificar a quantidade de grupos ideais para essa base de dados. Vale ressaltar que essa quantidade foi diferente do que foi utilizado no método de agrupamento, que foi passado como parâmetro de forma direta.

Referências

[1] Ross QUILAN. Auto mpg dataset, 2022.

[2] Caroline TOMASINI. Seleção automática de índices internos de validação de agrupamento., 2022.