Universidade do Estado de Minas Gerais
Graduação em Engenharia da Computação
Sistemas Inteligentes II
Trabalho 1

Sofia Anita Miranda

23 de Dezembro de 2022

1 Descrição dos Dados

O dataset utilizado para o desenvolvimento desse trabalho contém um conjunto de informações que são relevantes para a determinação dos preços de diamantes, assim como os preços preditos para cada uma das pedras listadas. Analisando as informações do dataset, observa-se que ele é composto por 53940 instâncias, e são descritas por 11 atributos, sendo eles apresentados na Tabela 2

Tabela 1: Descrição dos dados - Dataset Diamonds

Nº	Nome	Descrição	Valor mín.	Valor máx.	Valor Médio	Desvio Padrão	Var.
1	Unnamed	Indice	-	-	-	-	-
2	Carat (Quilate)	Peso em Quilates	0.2	5.1	0.797	0.473	2.24
3	Cut (Corte)	Qualidade do corte	Fair	Very Good	-	-	-
4	Color (Cor)	Cor do diamante	D	J	-	-	-
5	Clarity (Clareza)	Quão claro é o diamante	I1	WS2	-	-	-
6	Depth (profundidade)	Porcentagem da profundidade total	43.0	79.0	61.74	1.43	2.05
7	Table (Mesa)	Largura da mesa do topo do losango em relação ao ponto mais largo	43.0	95.0	57.45	2.23	4.99
8	Price (Preço)	Preço em dolares americano	326	18823	3930.99	3987.28	1.58
9	x	comprimento	3.73	10.74	5.73	1.11	1.25
10	y	largura	3.68	58.9	5.73	1.14	1.29
11	z	profundidade	1.07	31.8	3.54	0.70	4.93

Esse é um dataset que pode ser encontrado no repositório da Kaggle, que é uma comunidade online subsidiária da Google LLC, voltada para cientistas de dados e praticantes de aprendizado de máquina.

2 Análise dos Dados

Partindo para a análise dos dados, o principal objetivo é realizar a limpeza dos dados para depois serem utilizados em métodos voltados para o aprendizado de máquina. Para isso, foram seguidos alguns passos, sendo eles: verificação de correlação das variaveis e outliers, assim como fazer o pré-processamento desses dados.

No primeiro passo, foi verificado a correlação das variaveis para entender melhor a relação entre os dados. Para isso, foi gerado uma matriz que está representada pela figura 1. Através dela pode-se observar que as cores mais saturadas representam uma maior correlação entre atributos, enquanto as cores mais claras representam uma baixa correlação.

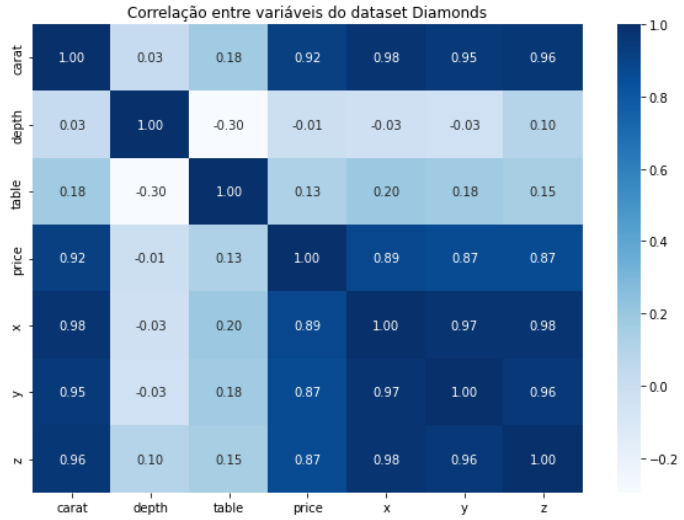


Figura 1: Matriz de correlação

No segundo passo, o objetivo foi analisar a dispersão dos dados, afim de verificar a existência de valores aberrantes. Com esse propósito foi gerado um gráfico onde é possível verificar a dispersão de cada instância de acordo com cada atributo. Esse gráfico pode ser visto na imagem 2. Aqui percebe-se como outliers aquelas instâncias que estão fora do agrupamento geral. Contudo, essas amostras foram mantidas na base já que elas podem representar apenas algumas pedras fora do padrão, e não como um dado com algum tipo de erro.

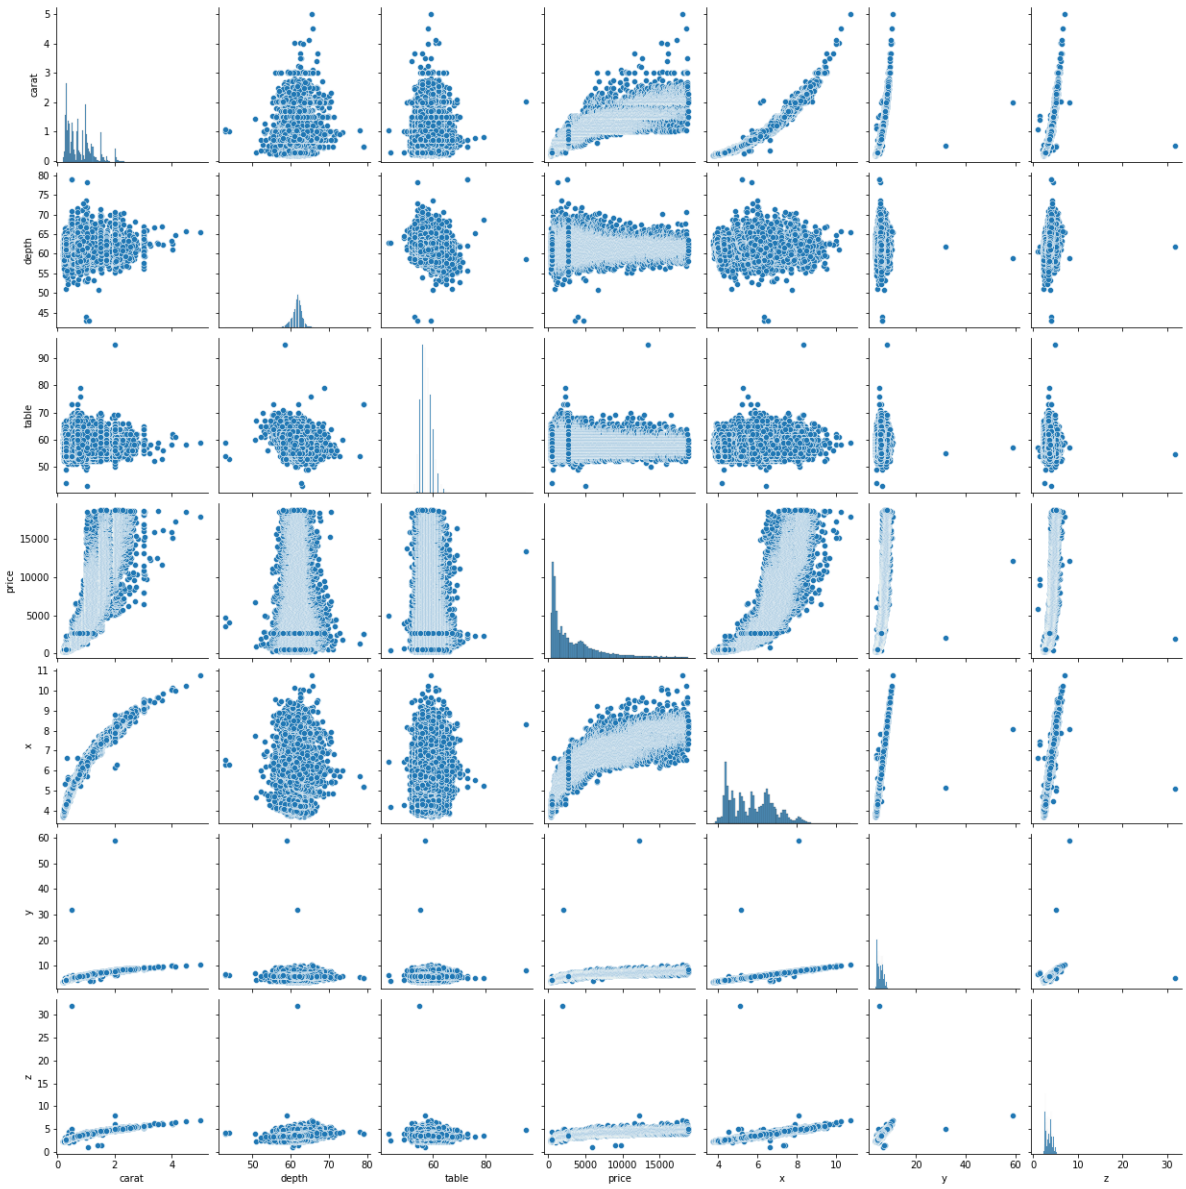


Figura 2: Dispersão dos dados

Com essas análises finalizadas, a etapa seguinte foi realizar o pré-processamento desses dados. Aqui, foi verificado a existência de valores nulos ou ausentes e dados duplicados, o que não foi encontrado. Contudo, sabendo que as colunas x, y e z representam as dimensões dos diamantes em um plano cartesiano, as instâncias que possuem valor zero nessas colunas foram removidas. Com isso, foram retiradas 20 amostras da base de dados.

Além disso também foi realizado uma análise dos atributos do dataset. Percebe-se que o primeiro representa um índice das instâncias. Como essa não é uma coluna importante para o objetivo desse trabalho ela foi removida.

Outro passo importante no pré-processamento desses dados foi a transformação de dados e separação da coluna ”Price”da base de dados. A transformação dos dados diz respeito a conversão dos atributos categoricos em numéricos, visto que o algoritmo trabalha apenas com valores númericos. Já a separação da coluna foi uma medida tomada para que posteriormente fosse possível comparar o valor previsto pelo

algoritmo para os diamantes, e assim verificar a eficiencia do aprendizado do método.

3 Metodologia

Com o objetivo de obter um modelo que consiga fazer boas previsões, foi utilizado o modelo Grid Search. Esse método faz todas as combinações possíveis dos parâmetros preditos (hiperparâmetros), e é retornado a melhor combinação.

Quando ao modelo de classificação, foi utilizado o K vizinhos mais proximos, e os valores passados como hiperparâmetro foram escolhidos de forma aleatória. Já para o modelo preditivo, foi aplicado uma Árvore de Decisão, que procura por comparações e desigualdades sobre os dados de entrada, com o intuíto de predizer uma variável de saída.

Com esse modelo preparado, foi passado para o Grid Search fazer as combinações. Por ser um modelo com alto custo computacional, foi realizado apenas duas repetições. Para validar o resultado, foi utilizado o modelo k-fold, que é um método de validação cruzada. Descreve o método de Classificação/Regressão, a abordagemd e validação cruzada e as métricas utilizadas.

4 Experimentos Computacionais

Na Tabela 2 é possível analisar as variações utilizadas no algoritmo.

Tabela 2: Parâmetros usados em Grid-Search com validação cruzada.

Modelo	Parâmetros	Variação
KNN	neighbors	1,2,3,4,5
DT	max depth	None, 1,2,3,4,5

Já a Tabela apresenta os resultados obtidos com os métodos de validação R^2, MAE e MSE.

Tabela 3: Resultados

Iteração	Modelo	R^2	MAE	MSE	Melhores Parâmetros
1	KNN	0.9544	436.3857	729474.04664 weights: distance	n neighbors: 6
1	DT	0.9639	368.9331	576838.1173	'max depth': None
2	KNN	0.9548	442.6879	745232.4672 'weights': 'distance'	'n neighbors': 10
2	DT	0.9654	364.2319	570761.1960	'max depth': None

5 Conclusão

Conforme os resultados obtidos, percebe-se que os melhores parâmetros encontrados, apesar de ambos os métodos e iteração terem resultados muito próximos, foi utilizando a arvore de decisão, principalmente na segunda iteração.