Universidade do Estado de Minas Gerais
Graduação em Engenharia da Computação
Optativa IV - Redes Neurais Artificiais
Trabalho 1

Sofia Anita Miranda

12 de dezembro de 2022

1 Introdução

Para o desenvolvimento deste trabalho, foram utilizadas duas bases de dados distintas. A primeira, Covid Brasil, refere-se a um histórico de infecções pelo vírus covid-19, assim como quantidade de obitos e a relação de vacinação no país. Já a segunda, Cardio Train possui informações á respeito da saúde de pacientes que podem ser classificados como saudáveis ou portadores de doenças cardiovasculares.

Para as duas bases foi aplicado um algoritmo de aprendizado de máquina baseado em redes neurais artificiais, com o intuito de fazer uma análise para observar a eficiência dos métodos estudados nas aulas de Redes Neurais Artificiais deste semestre.

2 Covid Brasil

2.1 Descrição dos dados

A primeira base de dados possui os seguintes atributos:

1. Casos Semanais
2. Ano
3. Casos Semanais por Milhão
4. Mortes Semanais
5. MortesSemanais por Milhão
6. Total de Vacinações
7. Pessoas Vacinadas
8. Pessoas Totalmente Vacinadas
9. Vacinações Diárias
10. Total de Vacinações por Cem

11. Pessoas Vacinadas por Cem
12. Pessoas TotalmenteVacinadas por Cem
13. Vacinações,Diárias por Cem
14. Pessoas diárias vacinadas
15. Pessoas diárias vacinadas por cem
16. Mortes da próxima semana

A quantidade de instâncias que existem nessa base é igual à 53940.

2.2 Pré-processamento

Nessa etapa, o principal objetivo é analisar os dados presentes na base, buscando tratar qualquer informação que possa reduzir a eficiência do método aplicado. Partindo da observação dos dados categóricos, foi verificado que todos já eram do tipo ponto flutuante, o que já eliminou a etapa de transformação desses dados.

Outro ponto importante analisado foi a existência de dados nulos que poderiam prejudicar o aprendizado do algoritmo. Nesse caso também não foi encontrado. Dessa forma, o passo seguinte foi separar a coluna "Mortes Semanais"do restante, já que essa coluna seria utilizada para verificar a eficiência do treinamento do algoritmo.

Com esses passos finalizados, os dados já estão prontos para serem empregados à um modelo de Redes Neurais Artificiais para aprender o padrão de casos de infecção que levaram a obito.

2.3 Aplicação do método

Para essa base de dados foi utilizado o método Maquina de Aprendizado Extremo para problemas de regressão, visto que o intuito é predizer a quantidade de mortes semanais. Além disso, para divisão da base em treinamento e teste foi utilizado o método de validação Holdout, e a avaliação foi feita utilizando o método r-quadrado.

Os parâmetros que representam a função de ativação e o tamanho da camada oculta foram alterados conforme a tabela 1:

Tabela 1: Análise dos dados - RNA Máquina de aprendizagem extremo aplicado ao problema Predição de mortes semanais referentes a infecção pelo vírus Covid-19

	Tamanho da camada oculta	Função de ativação	R-quadrado
clf 1	50	Unidade Linear Retificada	-1946112,82
clf 2	50	Tangente hiperbólica	0,5141
clf 3	75	Unidade Linear Retificada	-105523,4240
clf 4	75	Tangente hiperbólica	0,5593
clf 5	100	Unidade Linear Retificada	-315689.5714
clf 6	100	Tangente hiperbólica	0,5024

2.4 Conclusão

Conforme a definição do método de validação r-quadrado, quanto maior o R-quadrado, melhor o modelo se ajusta aos seus dados. Assim, percebe-se que, em geral, a função de ativação Unidade Linear Retificada (ReLu) não foi uma boa escolha para o problema proposto. Já a função de ativação Tangente hiperbólica (TanH) trouxe melhores resultados, apesar de não serem ideais. Contudo, pode-se dizer que a variação dos parâmetros presentes na variável clf 4 foi a melhor.

Código disponível em: https://colab.research.google.com/drive/1CYEAgBHkt3AhFskso47j4hK2m9mx9Rot?usp=sha

3 Classificação de pacientes cardiovasculares

3.1 Descrição dos dados

Já a segunda base de dados é composta pelos seguintes atributos:

1. Identificador (id)
2. Idade
3. Gênerogender
4. Altura
5. Peso
6. Pressão arterial sistólica
7. Pressão arterial diastólica
8. Colesterol
9. Glicose
10. Fumar
11. Consumo de álcool
12. Atividade física
13. Presença ou ausência de doença cardiovascular

A quantidade de instâncias que existem nessa base é igual à 69301.

3.2 Pré-processamento

Analisando os atributos da tabela, percebe-se que a primeira coluna representa um índice das instâncias. Como essa não é uma coluna importante para a análise, ela foi removida.

O passo seguinte foi procurar valores nulos ou ausentes. Para isso foi aplicado a função de soma de valores nulos para cada coluna do data frame. Feito isso, o resultado mostrado foi que não haviam dados nulos nessa base.

Foi verificado também se a base possuía algum atributo categórico, o que também não foi encontrado. Feito isso a base já estava pronta para a aplicação em um tipo de RNA.

E para finalizar, como se trata de uma base de dados com um grande volume de dados, foi aplicado também uma função de seleção aleátoria de dez mil amostras para serem aplicadas ao método de redes neurais artificiais.

3.3 Aplicação do método

Para essa base de dados, o modelo aplicado foi o Multilayer Perceptron para problemas de classificação, visto que a intenção é classificar os pacientes que podem ser cardiácos. Quanto a divisão da base para treinamento e teste, também foi utilizado o método de validação Holdout. Já a avaliação foi realizada utilizando a acurácia.

Os parâmetros que representam a função de ativação e o tamanho da camada oculta foram alterados conforme a tabela 2:

Tabela 2: Análise dos dados - RNA Multilayer Perceptron aplicado ao problema de Classificação de pacientes cardiovasculare

	Tamanho da camada oculta	Função de ativação	Acurácia
rna 1	50	Unidade Linear Retificada	0,498
rna 2	50	Tangente hiperbólica	0,4988
rna 3	75	Unidade Linear Retificada	0,5144
rna 4	75	Tangente hiperbólica	0,4988
rna 5	100	Unidade Linear Retificada	0,5128
rna 6	100	Tangente hiperbólica	0,4988

3.4 Conclusão

Conforme a definição, o método de avaliação acurácia consiste em encontrar o percentual de acertos. Em linhas gerais, pode ser observado que utilizando a função de ativação Tangente hiperbólica, apesar da alteração do tamanho da camada oculta, a acurácia se manteve constante e seus valores não foram satisfatórios. Quanto a utilização da função Unidade Linear Retificada, que trouxe mais eficiência para o problema proposto. Considerando a variação de parâmetros, o melhor modelo foi aquele representado pela variável rna 3 da tabela 1.

Código disponível em: https://colab.research.google.com/drive/1MllsbdEoRrTi6wgQQo-ML-YNOoEKTp3J?usp=sha