Universidade do Estado de Minas Gerais
Graduação em Engenharia da Computação
Optativa IV - Redes Neurais Artificiais
Trabalho 1

Sofia Anita Miranda

12 de dezembro de 2022

1 Introdução

Para o desenvolvimento deste trabalho, foram utilizadas duas bases de dados distintas. A primeira, Classificação de Clientes, refere-se a um histórico de crédito oferecido aos clientes de uma instituição fictícia. Já a segunda, Predição de preço de Diamantes possui informações que influenciam na determinação do valor dessas pedras preciosas.

Para as duas bases foi aplicado um algoritmo de aprendizado de máquina baseado em redes neurais artificiais, com o intuito de fazer uma análise para observar a eficiência dos métodos estudados até o momento nas aulas de Redes Neurais Artificiais deste semestre.

2 Classificação de clientes

2.1 Descrição dos dados

A primeira base de dados possui os seguintes atributos:

1. Estado Civil
2. Número de dependentes
3. Renda familiar
4. Tipo de residência
5. Valor do bem a ser adquirido
6. Número de parcelas
7. Valor da parcela
8. Se o cliente possui telefone
9. Tempo de moradia(meses)
10. Classe

A quantidade de instâncias que existem nessa base é igual à 1500.

2.2 Pré-processamento

Nessa etapa, o principal objetivo é analisar os dados presentes na base, buscando tratar qualquer informação que possa reduzir a eficiência do método aplicado. Partindo da observação dos dados categóricos, foi verificado que todos já eram do tipo numérico inteiro, o que já eliminou a etapa de transformação desses dados.

Outro ponto importante analisado foi a existência de dados nulos que poderiam prejudicar o aprendizado do algoritmo. Nesse caso também não foi encontrado. Dessa forma, o passo seguinte foi separar a coluna "Classe"do restante, já que essa coluna seria utilizada para verificar a eficiência do treinamento do algoritmo.

Com esses passos finalizados, os dados já estão prontos para serem empregados à um modelo de Redes Neurais Artificiais para aprender o padrão de clientes que poderão beneficiados com o crédito da instituição.

2.3 Aplicação do método

Para essa base de dados, o modelo aplicado foi o Multilayer Perceptron para problemas de classificação, visto que a intenção é classificar os clientes que podem ser beneficiados. Quanto a divisão da base para treinamento e teste, foi utilizado o método de validação Holdout. Já a avaliação foi realizada utilizando a acurácia.

Os parâmetros que representam a função de ativação e o tamanho da camada oculta foram alterados conforme a tabela 1:

Tabela 1: Análise dos dados - RNA Multilayer Perceptron aplicado ao problema Classificação de clientes

	Tamanho da camada oculta	Função de ativação	Acurácia
rna 1	50	Unidade Linear Retificada	0,7386
rna 2	50	tangente hiperbólica	0,8000
rna 3	75	Unidade Linear Retificada	0,72
rna 4	75	tangente hiperbólica	0,7546
rna 5	100	Unidade Linear Retificada	0,8213
rna 6	100	Unidade Linear Retificada	0,8080

2.4 Conclusão

Vale lembrar que o método de avaliação acurácia consiste em encontrar o percentual de acertos. Assim, o modelo que trouxe mais eficiência para o problema proposto, conforme os parâmetros passados, foi aquele representado pela variável rna 5 da tabela 1.

Código disponível em: Exercicio 1

3 Predição de preço de Diamantes

3.1 Descrição dos dados

Já a segunda base de dados é composta pelos seguintes atributos:

1. Unnamed
2. Carat (Quilate)
3. Cut (Corte)
4. Color (Cor)
5. Clarity (Clareza)
6. Depth (profundidade)
7. Table (Mesa)
8. Price (Preço)
9. x
10. y
11. z

A quantidade de instâncias que existem nessa base é igual à 53940.

3.2 Pré-processamento

Analisando os atributos da tabela, percebe-se que a primeira coluna representa um índice das instâncias. Como essa não é uma coluna importante para a análise, ela foi removida.

O passo seguinte foi procurar valores nulos ou ausentes. Sabendo que as colunas x, y e z representam as dimensões dos diamantes em um plano cartesiano. Logo as instâncias que possuem valor zero nessas colunas foram removidas. Com isso, foram retiradas 20 amostras da base de dados.

E para finalizar, como a base possuí atributos categóricos, foi necessário transformá-los em atributos numéricos. Feito isso a base já estava pronta para a aplicação em um tipo de RNA.

3.3 Aplicação do método

Para essa base de dados foi utilizado o método Maquina de Aprendizado Extremo para problemas de regressão, visto que o intuito é predizer um valor exato para um diamante. Além disso, para divisão da base em treinamento e teste foi utilizado o método de validação Holdout, e a avaliação foi feita utilizando o método r-quadrado.

Como no problema anterior, os parâmetros que representam a função de ativação e o tamanho da camada oculta foram alterados conforme a tabela 2:

Tabela 2: Análise dos dados - RNA Máquina de aprendizagem extremo aplicado ao problema Predição de preço de diamantes

	Tamanho da camada oculta	Função de ativação	R-quadrado
clf 1	50	Unidade Linear Retificada	0,8925
clf 2	50	Tangente hiperbólica	-2228,6812
clf 3	75	Unidade Linear Retificada	0,8168
clf 4	75	Tangente hiperbólica	-11708,0641
clf 5	100	Unidade Linear Retificada	0,8422
clf 6	100	Tangente hiperbólica	-15709,3857

3.4 Conclusão

Conforme a definição do método de validação r-quadrado, quanto maior o R-quadrado, melhor o modelo se ajusta aos seus dados. Assim, percebe-se que, em geral, a função de ativação Tangente hiperbólica não foi uma boa escolha para o problema proposto. Já a função de ativação Unidade Linear Retificada (ReLu) trouxe melhores resultados, apesar de não serem ideais. Contudo, pode-se dizer que a variação dos parâmetros presentes na variável clf 5 foi a melhor.

Código disponível em: Exercício 2